

IS-Proiect

Alexandra Sabău

January 2026

Cuprins

1	Introducere	1
2	Partea 1: Sistem electric — identificare de ordin II prin regresie liniară (trepte)	1
2.1	Scopul experimentului	1
2.2	Achiziția datelor	1
2.3	Estimarea factorului de proporționalitate K	2
2.4	Estimarea părții reale a polilor prin regresie liniară	2
2.5	Estimarea părții imaginare a polilor (pulsăția de oscilație)	4
2.6	Determinarea lui ω_n și ζ	4
2.7	Construirea modelului și validare	4
2.8	Observații	5
2.9	Concluzii (Partea 1)	5
3	Proiect 3: Circuit electric — identificare în frecvență cu semnal Chirp (VCO)	5
3.1	Scop	5
3.2	Calibrarea semnalului Chirp (VCO)	6
3.3	Achiziția datelor și filtrare	6
3.4	Estimarea lui K din regiunea de frecvențe joase	7
3.5	Identificarea rezonanței: M_r și ω_r	8
3.6	Determinarea lui ζ și ω_n	8
3.7	Validare în timp: simulare model și eroare	8
3.8	Observații	9
3.9	Concluzii (Partea 2)	10
4	Partea 3: Convertor DC–DC — identificare offline cu intrare SPAB	10
4.1	Scopul experimentului	10
4.2	Configurarea experimentului și generarea intrării	10
4.3	Selectarea subseturilor de date și pre-procesare	11
4.4	Datele folosite în identificare (Matlab)	12
4.5	Criterii de validare: reziduuri și potrivire	12
4.6	Modele estimate și alegerea parametrilor de structură	12
4.7	Analiza proprietăților modelelor valide (stabilitate, singularități, regim staționar)	13
4.8	Rezultate grafice (resid + compare) pe perechi	14
4.9	Tabel sinteză, modele eligibile și selecția modelului final	16
4.10	Concluzii (Partea 3)	17

1 Introducere

Lucrarea de față urmărește aplicarea etapelor principale din identificarea sistemelor pe baza unor experimente realizate în Simulink/Matlab. Pentru fiecare etapă se pornește de la un singur experiment, se aleg subseturi relevante de date pentru identificare și validare, se aplică pre-procesări (ex. centrare, filtrare, subeșantionare), apoi se estimează parametrii/modelul și se verifică validitatea prin criterii obiective.

În Partea 1 se identifică un model de ordin II în domeniul continuu din răspunsul la treaptă (estimarea lui K , ζ , ω_n). În Partea 2 se realizează identificare în frecvență folosind un semnal chirp (VCO), cu accent pe calibrare și reducerea zgomotului. În Partea 3 se identifică offline un model pentru convertorul DC–DC folosind o intrare de tip SPAB, iar modelele sunt comparate unitar pe baza testelor statistice pe reziduuri și a potrivirii pe setul de validare.

2 Partea 1: Sistem electric — identificare de ordin II prin regresie liniară (trepte)

2.1 Scopul experimentului

Se urmărește identificarea unui model de ordinul II cu poli complex-conjugați, pe baza unui singur experiment cu semnal de intrare de tip treaptă (cel puțin două niveluri). Modelul țintă este:

$$H(s) = \frac{K\omega_n^2}{s^2 + 2\zeta\omega_n s + \omega_n^2}, \quad (1)$$

unde K este factor de proporționalitate, ω_n pulsația naturală, iar ζ factorul de amortizare.

2.2 Achiziția datelor

Semnalele t , $u(t)$ și $y(t)$ au fost obținute prin simularea schemei electrice în Simulink. Intrarea conține două trepte suficient de lungi pentru a atinge regim staționar, iar ieșirea prezintă un răspuns oscilant amortizat. Figura 1 prezintă intrarea și ieșirea măsurate.




Figure 1: Semnalul de intrare $u(t)$ (trepte) și ieșirea $y(t)$ (răspuns oscilant amortizat).

2.3 Estimarea factorului de proporționalitate K

Acesta arată cu cât se schimbă ieșirea în regim staționar atunci când intrarea se schimbă cu o anumită valoare. Se calculează din două puncte staționare:

$$K = \frac{y_{st} - y_0}{u_{st} - u_0}. \quad (2)$$

În implementare, valorile u_0, u_{st}, y_0, y_{st} au fost estimate ca medii pe intervale în care semnalele sunt stabilizate.

Rezultatul obținut:

$$K = 3.9075.$$

2.4 Estimarea părții reale a polilor prin regresie liniară

Într-un răspuns oscilant amortizat, ieșirea se apropie treptat de valoarea finală y_{st} . Ca să măsurăm cât de departe este ieșirea față de această valoare la fiecare moment, definim:

$$y_{aux}(t) = |y(t) - y_{st}|. \quad (3)$$

Acest semnal reprezintă "distanța" față de regimul staționar (ignorând semnul) și descrește aproximativ exponențial.

Pentru maximele locale t_k ale lui $y_{aux}(t)$ se poate scrie aproximativ:

$$y_{aux}(t_k) \approx c e^{\Re\{\hat{s}\} t_k}. \quad (4)$$

Aplicând logaritmarea se obține o relație liniară:

$$\ln(y_{\text{aux}}(t_k)) = \Re\{\hat{s}\} t_k + b, \quad (5)$$

iar $\Re\{\hat{s}\}$ se estimează prin metoda celor mai mici pătrate folosind cel puțin trei maxime. Figura 2 arată semnalul auxiliar, iar Figura 3 arată regresia liniară în plan logaritm.




Figure 2: Semnalul auxiliar $y_{\text{aux}}(t) = |y(t) - y_{st}|$ folosit pentru identificarea amortizării.




Figure 3: Regresia liniară a punctelor $(t_k, \ln(y_{\text{aux}}(t_k)))$; panta reprezintă $\Re\{\hat{s}\}$.

2.5 Estimarea părții imaginare a polilor (pulsăția de oscilație)

Partea imaginară a polilor corespunde pulsăției de oscilație:

$$\omega_{osc} = \Im\{\hat{s}\} = \frac{2\pi}{T_{osc}}, \quad (6)$$

unde T_{osc} este perioada oscilației, estimată din timpul dintre un maxim și minimul următor, înmulțit cu 2.

Rezultatul obținut:

$$\omega_{osc} = 4.2038 \cdot 10^3 \text{ rad/s.}$$

2.6 Determinarea lui ω_n și ζ

Pentru poli complex-conjugați $\hat{s}_{1,2} = \Re\{\hat{s}\} \pm j\Im\{\hat{s}\}$, parametrii standard ai sistemului de ordin II sunt:

$$\omega_n = \sqrt{\Re\{\hat{s}\}^2 + \Im\{\hat{s}\}^2}, \quad \zeta = -\frac{\Re\{\hat{s}\}}{\omega_n}. \quad (7)$$

În urma calculelor:

$$\omega_n = 4.6526 \cdot 10^3 \text{ rad/s}, \quad \zeta = 0.4285.$$

2.7 Construirea modelului și validare

Modelul (1) a fost implementat în spațiul stărilor, în forma canonică:

$$A = \begin{bmatrix} 0 & 1 \\ -\omega_n^2 & -2\zeta\omega_n \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ K\omega_n^2 \end{bmatrix} \quad (8)$$

$$C = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad D = 0. \quad (9)$$

Ieșirea simulată $\hat{y}(t)$ a fost obținută cu `lsim` și comparată cu ieșirea măsurată $y(t)$.

Calitatea potrivirii a fost cuantificată prin:

$$J = \frac{1}{\sqrt{N}} \|y - \hat{y}\|_2, \quad \varepsilon_{MPN} = \frac{\|y - \hat{y}\|_2}{\|y - \bar{y}\|_2} \cdot 100\%. \quad (10)$$

Rezultatele obținute:

$$J = 88.8303, \quad \varepsilon_{MPN} = 8.4806\%.$$

J reprezintă eroarea RMS dintre ieșirea măsurată și cea simulată (adică „cât de mare este eroarea, în medie”).

Cum $\varepsilon_{MPN} < 10\%$, modelul este considerat valid conform criteriului impus.




Figure 4: Validare: comparație între ieșirea măsurată $y(t)$ și ieșirea simulată $\hat{y}(t)$.

2.8 Observații

Pulsația de oscilație $\omega_{osc} = 4.2038 \cdot 10^3$ rad/s corespunde unei frecvențe

$$f_{osc} = \frac{\omega_{osc}}{2\pi} \approx 669 \text{ Hz},$$

iar factorul de amortizare $\zeta = 0.4285$ arată că răspunsul are oscilații, însă amplitudinea lor scade în timp. În grafic se observă că, după aplicarea treptei, ieșirea depășește pentru scurt timp valoarea staționară y_{st} și apoi oscilează în jurul ei, cu amplitudine descrescătoare. .

2.9 Concluzii (Partea 1)

S-a realizat identificarea unui model de ordin II din răspunsul la treaptă folosind: (i) factor de proporționalitate K , (ii) regresia liniară a $\ln(|y - y_{st}|)$ pentru estimarea amortizării, (iii) perioada oscilației pentru componenta imaginară a polilor. Modelul identificat reproduce adecvat dinamica principală, iar $\varepsilon_{MPN} = 8.48\%$ confirmă validarea.

3 Proiect 3: Circuit electric — identificare în frecvență cu semnal Chirp (VCO)

3.1 Scop

În această etapă se identifică parametrii unui model de ordin II cu poli complex-conjugați utilizând un experiment cu semnal de intrare de tip Chirp (VCO). Structura aleasă este:

$$H(s) = \frac{K \omega_n^2}{s^2 + 2\zeta\omega_n s + \omega_n^2}, \quad (11)$$

unde K este factor de proporționalitate, ζ factorul de amortizare, iar ω_n pulsația naturală.

3.2 Calibrarea semnalului Chirp (VCO)

Conform principiilor de calibrare, semnalul Chirp se alege astfel încât: (i) gama de frecvențe $[f_{\min}, f_{\max}]$ să permită observarea atât a câștigului la frecvențe joase (pentru K), cât și a zonei de rezonanță (pentru ζ și ω_n); (ii) durata experimentului să fie suficientă pentru atingerea frecvențelor intermediare; (iii) amplitudinea să nu conducă la saturații.

În implementare s-a utilizat o pulsație de referință

$$\omega_f = 4646 \text{ rad/s},$$

aleasă în jurul valorii obținute anterior din experimentul cu treaptă (pentru a asigura trecerea prin zona de rezonanță). Amplitudinea intrării a fost:

$$A_{in} = 1.25.$$

3.3 Achiziția datelor și filtrare

Semnalele $u(t)$ și $y(t)$ au fost obținute prin simularea modelului `circuit_electric_R2022b_chirp.slx`. S-a observat că semnalele sunt puternic oscilante și zgomotoase, iar estimarea amplitudinilor direct din datele brute produce variații semnificative ale parametrilor estimați (și implicit o eroare de validare mai mare).

Pentru a reduce zgomotul fără a deforma semnificativ forma locală a semnalului sinusoidal, s-a aplicat filtrare Savitzky–Golay (ordin 1, fereastră 41) atât pe intrare, cât și pe ieșire:

$$u_f(t) = \text{sgolayfilt}(u, 1, 41), \quad y_f(t) = \text{sgolayfilt}(y, 1, 41).$$

Figura 5 arată un zoom pe semnalele nefiltrate, iar Figura 6 arată aceeași zonă după filtrare (se observă reducerea zgomotului).




Figure 5: Zoom pe semnalele $u(t)$ și $y(t)$ fără filtrare (zgomot vizibil).




Figure 6: Zoom pe semnalele $u(t)$ și $y(t)$ după filtrare Savitzky–Golay (zgomot redus).

Figura 7 prezintă semnalul filtrat pe întreaga durată a experimentului.




Figure 7: Semnalul Chirp pe întreaga durată (intrare și ieșire filtrate).

3.4 Estimarea lui K din regiunea de frecvențe joase

În zona de frecvențe joase, modulul funcției de transfer este aproximativ constant, astfel încât:

$$K \approx \frac{A_y}{A_u}, \quad (12)$$

unde A_u este amplitudinea intrării, iar A_y amplitudinea ieșirii, estimate din maxime/minime.

Din datele experimentale (după filtrare) s-a obținut:

$$K = 3.8500.$$

3.5 Identificarea rezonanței: M_r și ω_r

În zona în care amplitudinea ieșirii atinge un maxim (rezonanță), se estimează:

$$M_r \approx \frac{A_y^r}{A_u^r}. \quad (13)$$

Din date a rezultat:

$$A_y^r = 1.1966, \quad M_r = 0.9573.$$

Pulsația de rezonanță se obține din perioada oscilației în zona respectivă:

$$\omega_r \approx \frac{\pi}{\Delta t}, \quad (14)$$

unde Δt este distanța temporală dintre două extreme consecutive ale răspunsului (de exemplu, un maxim și următorul minim), adică aproximativ jumătate de perioadă.

iar din măsurători s-a obținut:

$$\omega_r = 4.2604 \cdot 10^3 \text{ rad/s.}$$

3.6 Determinarea lui ζ și ω_n

Pentru sistemul de ordin II, rezonanța (dacă există) este legată de ζ și ω_n prin:

$$\omega_r = \omega_n \sqrt{1 - 2\zeta^2}, \quad \zeta \in \left(0, \frac{\sqrt{2}}{2}\right). \quad (15)$$

Pe baza estimărilor din experiment s-a utilizat:

$$\zeta = 0.3781,$$

iar ω_n a rezultat din (15):

$$\omega_n \approx 5.04 \cdot 10^3 \text{ rad/s.}$$

(Valoarea a fost calculată din ω_r și ζ .)

3.7 Validare în timp: simulare model și eroare

Modelul (11) a fost implementat în spațiul stărilor (formă canonică):

$$A = \begin{bmatrix} 0 & 1 \\ -\omega_n^2 & -2\zeta\omega_n \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ K\omega_n^2 \end{bmatrix}, \quad C = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad D = 0. \quad (16)$$

Ieșirea simulată $\hat{y}(t)$ a fost obținută cu `lsim`. Deoarece începutul semnalului chirp este sensibil la condițiile inițiale, s-au utilizat condiții inițiale nenule în simulare (aproximate din date) pentru a îmbunătăți supra-punerea inițială.

Indicii de performanță utilizați:

$$J = \frac{1}{\sqrt{N}} \|y - \hat{y}\|_2, \quad \varepsilon_{MPN} = \frac{\|y - \hat{y}\|_2}{\|y - \bar{y}\|_2} \cdot 100\%. \quad (17)$$

Rezultatele obținute (după filtrare):

$$J = 0.1821, \quad \varepsilon_{MPN} = 6.7922\%.$$

Cum $\varepsilon_{MPN} < 10\%$, modelul este validat conform criteriului impus.




Figure 8: Validare: suprapunere între ieșirea măsurată $y(t)$ (roșu) și ieșirea simulată $\hat{y}(t)$ (galben).

3.8 Observații

S-a constatat că estimarea parametrică este sensibilă la zgomotul din semnale, deoarece K , M_r și ω_r se determină din amplitudini și perioade citite din grafic. Aplicarea filtrării Savitzky–Golay pe u și y a redus semnificativ variațiile locale și a permis obținerea unei erori normalizate sub pragul de 10%.

De asemenea, o ajustare fină a lui ζ în jurul valorii calculate poate conduce la o eroare ușor mai mică; în testele efectuate, o valoare $\zeta \approx 0.3850$ a produs o eroare marginal mai mică decât valoarea obținută strict din calcul.

Table 1: Rezultate numerice obținute pentru identificarea cu semnal Chirp (VCO).

Mărime	Valoare
Pulsație de referință (calibrare) ω_f [rad/s]	4646
Amplitudinea intrării A_{in}	1.25
Factor de proporționalitate K	3.8500
Amplitudine la rezonanță A_y^r	1.1966
Modul la rezonanță M_r	0.9573
Pulsație de rezonanță ω_r [rad/s]	$4.2604 \cdot 10^3$
Factor de amortizare ζ	0.3781
Pulsație naturală ω_n [rad/s]	$\approx 5.04 \cdot 10^3$
Indicator J	0.1821
Eroare normalizată ε_{MPN} [%]	6.7922

3.9 Concluzii (Partea 2)

Folosind semnalul Chirp (VCO) s-au estimat parametrii K , ω_r , M_r , apoi ζ și ω_n pentru un model de ordin II. Validarea în timp arată o suprapunere bună între $y(t)$ și $\hat{y}(t)$, iar $\varepsilon_{MPN} = 6.79\%$ confirmă îndeplinirea cerinței.

4 Partea 3: Convertor DC–DC — identificare offline cu intrare SPAB

4.1 Scopul experimentului

Se urmărește identificarea unui model al convertorului DC–DC pe baza **unui singur experiment** cu intrare de tip *SPAB* (Semnal Pseudo-Aleator BinAR) suprapus peste un profil lent (trapez- rampa, platou). Conform cerințelor, se estimează și se validează: (i) un model **valid prin autocorelație** (ARX/ARMAX), (ii) un model **valid prin intercorelație** (IV4/OE/BJ), (iii) un model **de altă natură** (de tip spațiul stărilor: N4SID/SSEST), apoi se selectează un **model final** pe un criteriu unitar.

4.2 Configurarea experimentului și generarea intrării

Parametrii experimentului sunt calculați pe baza numerelor primite ($m = 6$, $n = 13$), iar semnalul de intrare $u(t)$ (factor de umplere) este generat cu funcția `generate_input_signal`, folosind: durata inițială t_1 , timpul de urcare t_r , ordinul SPAB N și prescalerul p . Aceste alegeri impun o durată totală T_{fin} și un pas de eșantionare compatibile cu limitările de achiziție.

Figura 9 prezintă semnalele măsurate în experiment: intrarea $u(t)$ și ieșirea $y(t)$.




Figure 9: Semnalele măsurate în experimentul cu intrare SPAB: $u(t)$ (sus) și $y(t)$ (jos).

4.3 Selectarea subseturilor de date și pre-procesare

Pentru identificare și validare s-au extras subseturi din semnalele brute folosind indicii $i_1, \dots, i_4$ și un factor de subeșantionare N_r :

$$t_{id} = t(i_1 : N_r : i_4), \quad u_{id} = u(i_1 : N_r : i_4), \quad y_{id} = y(i_1 : N_r : i_4),$$

$$t_{vd} = t(i_3 : N_r : i_4), \quad u_{vd} = u(i_3 : N_r : i_4), \quad y_{vd} = y(i_3 : N_r : i_4).$$

Observație importantă: identificarea NU a fost făcută doar pe intervalul $[i_1, i_2]$, ci pe **întreg intervalul** $[i_1, i_4]$, iar validarea pe $[i_3, i_4]$.

În implementare s-au utilizat:

$$i_1 = 42702, \quad i_2 = 113809, \quad i_3 = 146015, \quad i_4 = 216399, \quad N_r = 19.$$

Subeșantionarea (N_r) reduce redundanța datelor (corelații puternice la eșantionare foarte fină) și face identificarea numeric mai robustă. Păstrăm doar din N_r în N_r puncte, astfel avem mai puține date aproape identice.

Pentru eliminarea offset-ului DC s-a aplicat centrare:

$$u \leftarrow u - \bar{u}, \quad y \leftarrow y - \bar{y}.$$




Figure 10: Ilustrare a subseturilor utilizate pentru identificare și validare (ferestrele definite de $i_1, \dots, i_4$).

4.4 Datele folosite în identificare (Matlab)

Seturile de date au fost construite cu `iddata` folosind pasul de eșantionare efectiv: `dat_id = iddata(y_id, u_id, t_id(2) - t_id(1)); dat_vd = iddata(y_vd, u_vd, t_vd(2) - t_vd(1));`

4.5 Criterii de validare: reziduuri și potrivire

Modelele au fost evaluate prin:

- **Potrivire pe setul de validare** (fit) din `compare(model, dat_vd);`
- **Testele statistice pe reziduuri** din `resid(model, dat_vd):`
 - **AutoCorr**: reziduul $e(t)$ trebuie să fie *alb* (corelațiile pentru lag-uri nenule în banda de încredere);
 - **XCorr(u1)**: eroarea trebuie să fie "independentă" de intrare - adică **nu se mai vede nicio legătură între u și eroare** (punctele rămân în banda de încredere).

Conform cerinței:

- **ARX, ARMAX** — se impune **autocorelația** (AutoCorr);
- **IV4, OE, BJ** — se impune **intercorelația** (XCorr);
- **N4SID, SSEST** — acceptat dacă trece **cel puțin unul** dintre teste.

4.6 Modele estimate și alegerea parametrilor de structură

În continuare sunt prezentate structurile alese (parametrii de ordin) exact ca în cod, împreună cu o justificare scurtă.

```
model_armax = armax(dat_id,[5 5 5 1]);
```

Alegerea $(na, nb, nc, nk) = (5, 5, 5, 1)$ oferă flexibilitate atât pe dinamica deterministă (A, B) , cât și pe modelarea zgomotului (C) , reducând autocorelația reziduului. În ARMAX, na și nb descriu relația intrare-ieșire (dinamica sistemului), nc descrie zgomotul (modelul erorii), iar nk este întârzierea în eșantioane dintre intrare și ieșire.

```
model_oe = oe(dat_id,[8 1 2]);
```

Alegerea $(nb, nf, nk) = (8, 1, 2)$ unui ordin mai mare pentru $B(q)$ ($nb=8$) ca să descrie mai bine influența intrării și să treacă testul de intercorelație (reziduul să nu depindă de intrare). În această configurație testul este satisfăcut, însă potrivirea pe setul de validare (fit) rămâne mică, deci modelul reproduce doar parțial dinamica sistemului.

```
model_bj = bj(dat_id,[2 2 3 8 2]);
```

Alegerea $(nb, nc, nd, nf, nk) = (2, 2, 3, 8, 2)$ oferă fit mare, însă la testul de intercorelație reziduul rămâne corelat cu intrarea, acest lucru înseamnă că modelul nu a captat complet efectul intrării, deci nu este acceptat conform criteriului cerut.

```
model_iv4 = iv4(dat_id,[2 2 1]);
```

Alegerea $(na, nb, nk) = (2, 2, 1)$ definește un model **compact**, adică are puțini parametri și nu este inutil de complicat. Este și **robust** deoarece metoda IV (variabile instrumentale) este mai puțin sensibilă la zgomot și la corelația dintre intrare și perturbări. În rezultatele obținute, modelul trece testul de intercorelație și are cel mai mare *fit* dintre modelele eligibile..

```
model_n4sid = n4sid(dat_id,14);
```

```
model_ssest = ssest(dat_id,3);
```

Ordinele $n_x = 14$ (N4SID) și $n_x = 3$ (SSEST) au fost alese astfel încât să ofere o potrivire bună, iar acceptarea se face dacă trec cel puțin unul dintre testele din **resid**.

4.7 Analiza proprietăților modelelor valide (stabilitate, singularități, regim staționar)

Deoarece datele sunt eșantionate și **iddata** este construit cu un timp de eșantionare, identificarea și validarea sunt realizate în mod **discret**. Un model discret este **stabil** dacă toți polii sunt în interiorul cercului unitate ($|p_i| < 1$).

IV4 (modelul selectat). Pentru IV4 s-au obținut poli:

$$p_{1,2} = 0.9848 \pm 0.0237j, \quad |p_{1,2}| \approx 0.9851 < 1,$$

deci modelul este **stabil**. Factorul de proporționalitate (din afișarea modelului) este:

$$K \approx 156.8172.$$

Regimul staționar (câștigul DC) pentru un model discret se evaluează la $z = 1$ (în practică: **dcgain**).

ARMAX. Modelul ARMAX rezultat este de tip **discret** (afișare **zpk** cu *Sample time* $T_s = 0.000494$ s). Din factorul de ordin doi din numitor, polii dominanți sunt un cuplu complex cu

$$|p_{1,2}| \approx 0.9856 < 1,$$

deci modelul este **stabil**. Fiind ARMAX, include și o componentă de zgomot, ceea ce explică îmbunătățirea testului de autocorelație față de structuri mai simple.


SSEST. În rularea raportată, **ssest** a fost afișat ca model **continuu** (zero/pole/gain în s), de forma:

$$G(s) = \frac{-15868(s - 53.11)(s + 1602)}{(s + 3045)(s^2 + 57.4s + 3015)}.$$


Polii sunt în semiplanul stâng ($s = -3045$ și rădăcinile lui $s^2 + 57.4s + 3015$), deci modelul este **stabil**. Apare însă un **zero în semiplanul drept** ($s = +53.11$), ceea ce indică **comportare neminim-fază** (răspuns invers inițial posibil). Chiar dacă modelul este continuu ca afișare, comparația/validarea în Matlab pe **dat_vd** rămâne coerentă (Matlab gestionează simularea în raport cu datele eșantionate).

4.8 Rezultate grafice (resid + compare) pe perechi

În continuare sunt prezentate pe perechi, pentru fiecare model: (stânga) **resid**, (dreapta) **compare**.




(a) **resid** ARMAX




(b) **compare** ARMAX (fit 81.81%)

Figure 11: ARMAX: testul de autocorelație este satisfăcut (în limitele benzii pentru lag-uri nenule) și potrivire bună pe validare.




(a) resid OE




(b) compare OE (fit 49.17%)

Figure 12: OE: intercorelația (XCorr) este acceptabilă, însă potrivirea pe validare este redusă.




(a) resid BJ




(b) compare BJ (fit 85.81%)

Figure 13: BJ: deși fit-ul este ridicat, testul de intercorelație indică dependență intrare-reziduu, deci modelul nu este eligibil pentru categoria IV/OE/BJ.




(a) resid IV4




(b) compare IV4 (fit 87.96%)

Figure 14: IV4: trece intercorelația (XCorr în bandă) și oferă fit maxim dintre modelele eligibile.




(a) resid N4SID




(b) compare N4SID (fit 79.08%)

Figure 15: N4SID: model de altă natură (spațiul stărilor), acceptat dacă trece cel puțin unul dintre teste.



(a) resid SSEST



(b) compare SSEST (fit 79.73%)

Figure 16: SSEST: model de altă natură (spațiul stărilor), cu proprietăți stabile; acceptarea se face pe cel puțin un test.

4.9 Tabel sinteză, modele eligibile și selecția modelului final

Table 2: Sinteza modelelor (validare pe `dat_vd`).

Model	Structură (cod)	Fit (%)	Verdict pe testul cerut
ARMAX	[5 5 5 1]	81.81	Trece autocorelația
OE	[8 1 2]	49.17	Trece intercorelația
BJ	[2 2 3 8 2]	85.81	Nu trece intercorelația
IV4	[2 2 1]	87.96	Trece intercorelația
N4SID	$n_x = 14$	79.08	Trece cel puțin un test
SSEST	$n_x = 3$	79.73	Trece cel puțin un test

Criteriul unitar de selecție adoptat a fost:

Model eligibil = trece testul statistic cerut metodei; dintre modelele eligibile se alege fit maxim pe validare.

Prin urmare, modelul **IV4** este ales ca **model final** (fit 87.96% și trece intercorelația). Modelul este stabil (polii $0.9848 \pm 0.0237j$, cu $|p| \approx 0.9851$) și are câștigul raportat $K \approx 156.8172$.

4.10 Concluzii (Partea 3)

S-au extras subseturi de date pentru identificare ($[i_1, i_4]$) și validare ($[i_3, i_4]$), cu centrare și subeșantionare, apoi s-au estimat modele din clase diferite. ARMAX este modelul eligibil din categoria autocorelație, IV4 este modelul eligibil cu fit maxim din categoria intercorelație, iar N4SID/SSEST oferă modele de altă natură acceptabile (trec cel puțin un test). Pe baza criteriului unitar, **IV4** este selectat ca model final, oferind cel mai bun compromis între potrivire și validarea statistică a reziduului.